

## Pemodelan Regresi Linear Untuk Prediksi Konsumsi Energi Primer Indonesia Menggunakan *Hybrid Particle Swarm Optimization* Dan *Continuous Ant Colony Optimization*

Faris Febrianto<sup>1</sup>, Candra Dewi<sup>2</sup>, Bayu Rahayudi<sup>3</sup>

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya

Email: <sup>1</sup>farisfebrianto@outlook.com, <sup>2</sup>dewi\_candra@ub.ac.id, <sup>3</sup>ubay1@ub.ac.id

### Abstrak

Prediksi konsumsi energi primer merupakan hal penting dalam mendasari kebijakan energi semua negara, akan tetapi banyak prediksi konsumsi energi primer tergolong tidak akurat dan kurangnya sumber data. Konsumsi energi primer Indonesia merupakan yang terbesar dibandingkan dengan konsumsi negara lain di kawasan Asia Tenggara dan terbesar keempat di kawasan Asia Pasifik. Konsumsi energi primer Indonesia mengalami peningkatan yang pesat sebagai akibat pertumbuhan ekonomi dalam beberapa tahun terakhir yakni meningkat 16% hanya dalam rentang tiga tahun yakni 149.31Mtoe pada tahun 2010 menjadi 174.24Mtoe tahun 2013. Konsumsi energi primer di Indonesia sebagian besar berasal dari energi fosil yakni minyak bumi, gas alam, dan batubara, sedangkan tenaga air dan energi terbarukan lainnya hanya 3.33% dari total konsumsi energi primer pada tahun 2016. Tujuan dari penelitian ini untuk menghasilkan prediksi konsumsi energi primer serealistik mungkin melalui parameter *Gross National Income*, *Gross Domestic Product*, jumlah populasi, impor, dan ekspor Indonesia. Prediksi konsumsi energi primer Indonesia dilakukan menggunakan regresi linear berganda dengan penentuan nilai intersep dan koefisien kemiringan regresi menggunakan *hybrid Particle Swarm Optimization* dan *Continuous Ant Colony Optimization*. Dari hasil pengujian pemodelan regresi linear yang terbentuk memiliki rata-rata nilai kesalahan *Mean Absolute Percentage Error* sebesar 10.1% yang menunjukkan bahwa metode yang digunakan termasuk dalam kategori baik digunakan dalam prediksi konsumsi energi primer Indonesia. Metode *hybrid* juga dibandingkan dengan penggunaan pemodelan regresi menggunakan *Particle Swarm Optimization* dan *Continuous Ant Colony Optimization* saja.

**Kata kunci:** optimasi kontinyu, prediksi konsumsi energi primer Indonesia, *Particle Swarm Optimization*, *Ant Colony Optimization*, regresi linear berganda, metode *hybrid*.

### Abstract

Primary energy consumption prediction is an important to project future government energy policy in any country. However, many primary energy consumption prediction often lack of accuracy and data sources. Indonesia primary energy consumption is the biggest than other country in south east asia region and fourth in asia pacific. Indonesia primary energy consumption always increased due to rapid economic growth in last few years, it raised 16% only in three years, 149.31Mtoe in 2010 to 174.24Mtoe in 2013. Indonesia primary energy sources from fossils energy, oil, gas, and coal, otherwise hydro energy, and other renewables energy only 3.33% from total consumption. Our aim is to create primary energy consumption prediction accurately from five input parameter, *Gross National Income*, *Gross Domestic Product*, population, import, and eksport. We use multiple linear regression modelling with find intercept and slope coefficient using *hybrid Particle Swarm Optimization* and *Continuous Ant Colony Optimization*. Experiment results shows that linear regression model has average *Mean Absolute Percentage Error* 10.1% which is good category for primary energy consumption prediction. Hybrid method also compared with regression using standalone *Particle Swarm Optimization* and standalone *Continuous Ant Colony Optimization*.

**Keywords:** continuous optimization, Indonesia primary energy consumption prediction, *Particle Swarm Optimization*, *Ant Colony Optimization*, multiple linear regression, hybrid method.

## 1. PENDAHULUAN

Energi primer merupakan energi yang diperoleh dari alam dan belum mengalami proses pengolahan lebih lanjut. Prediksi konsumsi energi primer merupakan hal penting dalam mendasari kebijakan energi semua negara untuk mencapai target perkembangan ekonomi, pemeliharaan lingkungan, dan ketepatan perencanaan pada sumber energi yang ada (Barak & Sadegh, 2016). Konsumsi energi primer Indonesia, mengalami peningkatan yang pesat sebagai akibat pertumbuhan ekonomi dalam beberapa tahun terakhir. Konsumsi energi primer pada tahun 2010 baru sekitar 149.31Mtoe dan bertambah menjadi 174.24Mtoe pada tahun 2013 atau mengalami peningkatan hampir 16% hanya dalam rentang tiga tahun. Untuk mengontrol konsumsi energi primer pemerintah mengeluarkan PP No. 79 tahun 2014 tentang Kebijakan Energi Nasional (KEN), dampaknya konsumsi energi primer nasional turun menjadi 162.9Mtoe pada tahun 2014. Konsumsi energi primer Indonesia merupakan yang terbesar dibandingkan dengan konsumsi negara lain di kawasan Asia Tenggara dan terbesar keempat di kawasan Asia Pasifik (Gambar 1).

Konsumsi energi primer di Indonesia berasal dari minyak bumi, gas alam, batubara, tenaga air, dan energi terbarukan lain berupa tenaga surya, tenaga angin, panas bumi, dan biomassa. Pada tahun 2016 konsumsi energi primer Indonesia sebesar 175.04Mtoe yang sebagian besar berupa energi fosil yakni 96.67% dari keseluruhan konsumsi energi primer atau 169.22Mtoe. Angka konsumsi energi primer dari fosil berasal dari minyak bumi (41.47%) pada konsumsi teratas disusul batubara (35.82%) dan gas alam (19.38%), sedangkan tenaga air dan energi terbarukan lain hanya menyumbang 3.33% dari total konsumsi energi primer pada tahun 2016.

Permasalahannya banyak prediksi konsumsi energi primer tergolong tidak akurat dan kekurangan sumber data (Barak & Sadegh, 2016). Prediksi konsumsi energi primer tergantung pada banyak faktor sosial-ekonomi seperti *gross domestic product* (GDP), populasi, impor, ekspor, tingkat pertumbuhan dan ketersediaan sumber energi (Kiran, et al., 2012). Akan tetapi, prediksi konsumsi energi merupakan hal yang sangat sulit dilakukan, karena beberapa hal lain seperti percepatan perkembangan ekonomi, penggunaan teknologi, dan keputusan pemerintah juga ikut

mempengaruhi. Menentukan parameter-parameter apa saja yang dibutuhkan untuk memodelkan prediksi konsumsi energi merupakan hal yang sulit karena membutuhkan penelitian lebih lanjut dan banyak data, dimana data tersebut banyak yang tidak tersedia. Oleh sebab itu, prediksi konsumsi energi dapat dicari dengan menggunakan persamaan matematika sederhana seperti regresi linear menggunakan data yang ada (Kiran, et al., 2012).

Diantara banyak macam metode *swarm intelligence*, *particle swarm optimization* (PSO) dan *ant colony optimization* (ACO) merupakan metode optimasi metaheuristik yang sering digunakan. Berbeda dengan PSO yang memang ditujukan untuk menyelesaikan permasalahan optimasi kontinyu, ACO banyak digunakan terutama untuk menyelesaikan permasalahan optimasi kombinatorial. ACO terinspirasi dari perilaku mencari makan kawanannya semut.

ACO biasa hanya bisa menyelesaikan permasalahan diskrit atau kombinatorial. Untuk mengaplikasikan ACO pada permasalahan kontinyu, variabel kontinyu sering kali diubah menjadi diskrit terlebih dahulu dengan ketelitian beberapa dibelakang koma. Pendekatan ini memiliki beberapa kelemahan terutama pada permasalahan pada ruang pencarian diantara range positif dan negatif, ruang pencarian atau kasus dengan dimensi yang sangat besar, atau pada kasus yang memerlukan ketelitian tinggi. Socha & Dorigo (2008) mengembangkan metode berbasis ACO dengan nama  $ACO_R$  untuk mengatasi permasalahan optimasi kontinyu.

Konvergensi dini yang menyebabkan set solusi jatuh ke *local minimum* mungkin terjadi pada PSO dan  $ACO_R$ . Konvergensi dini salah satunya disebabkan oleh kurangnya diversifikasi atau *global exploration* pada proses pencarian. Untuk mengatasi permasalahan ini para peneliti melakukan hibridasi yang menggabungkan dua metode *swarm intelligence* yang berbeda. Pada penelitian ini teknik hibridasi yang digunakan adalah teknik *hybrid* PSO dan  $ACO_R$  secara sekuensial yang dikembangkan oleh Huang & Huang (2013).

Tujuan dari penelitian ini untuk menghasilkan pemodelan regresi linear untuk memprediksi konsumsi energi primer serealistik mungkin melalui parameter *gross national income* (GNI), GDP, jumlah populasi, impor, dan ekspor Indonesia. Intersep dan kemiringan koefisien regresi dicari menggunakan hybrid dari PSO dan  $ACO_R$  ( $PSOACO_R$ ) secara sekuensial. Harapannya penelitian ini dapat

menjadi referensi bagi pihak perencanaan kebijakan energi nasional berdasarkan faktor-faktor yang berkaitan agar tidak terjadi defisit energi serta menjaga keseimbangan rasio konsumsi dengan produksi energi.



Gambar 1. Konsumsi energi primer di Asia Pasifik

## 2. PENELITIAN TERDAHULU

Pada banyak literatur, penelitian pada prediksi energi primer telah banyak dilakukan. Prediksi menggunakan *Autoregressive Integrated Moving Average* (ARIMA), *Artificial Neural Network* (ANN), *Grey Model*, *Genetic Algorithm* (GA), logika fuzzy, *Support Vector Regression* (SVR), *Ant Colony Optimization* (ACO), *Particle Swarm Optimization* (PSO), dan *Long-Range Energy Alternatives Planning* (LEAP) merupakan beberapa model yang paling banyak digunakan dalam penelitian prediksi energi primer (Suganthi & Samuel, 2012).

Deka, et al. (2016) membuat pemodelan untuk memprediksi kebutuhan energi primer Amerika Serikat menggunakan lima teknik yang berbeda yakni dua ANN, dua pemodelan regresi, dan satu ARIMA. Data yang digunakan mulai dari tahun 1950-2013 berupa data konsumsi energi primer, GDP, GNI, dan pendapatan per kapita. Hasil menggunakan model ANN pertama merupakan yang terbaik dengan RMSE pada data uji sebesar 1.99.

Kiran, et al. (2012) mengembangkan metode pemodelan regresi linear dan kuadratik menggunakan *hybrid* ACO (bukan kontinyu) dan PSO untuk memprediksi kebutuhan energi primer di Turki. Fungsi *fitness* yang dipakai berupa selisih kuadrat antara nilai aktual dan prediksi pada data latih. Data yang dipakai pada penelitian ini berupa data GDP, populasi, impor, dan ekspor negara Iran. Hasil pengujian menunjukkan metode yang digunakan memiliki

nilai *relative error* terkecil sebesar 20.54. Penggunaan metode *hybrid* tersebut juga lebih baik 8.79% daripada regresi linear – ACO dan lebih baik 2.14% dari regresi linear – PSO.

Pada tahun 2013, Huang & Huang melakukan empat tipe hibridasi antara *continuous ant colony optimization* (ACO<sub>R</sub>) dan PSO untuk diaplikasikan pada permasalahan klustering. Empat tipe hibridasi tersebut yakni sekuensial, paralel, sekuensial dengan memperbesar tabel partikel, dan perbandingan *global best*. Dari empat tipe hybrid tersebut yang terbaik adalah sekuensial dengan memperbesar tabel partikel karena tabel partikel yang diperbesar menambah diversifikasi (*global exploration*) pada PSO dan ACO<sub>R</sub>, efek ini sama dengan memperbesar *popSize* itu sendiri karena tabel partikel menjadi dua kali lipat lebih besar dari yang awal. Hasil terbaik kedua adalah tipe sekuensial biasa tanpa perlu memperbesar tabel partikel.

Dari penelitian-penelitian sebelumnya tersebut maka pada penelitian ini metode yang digunakan berupa pemodelan regresi linear menggunakan *hybrid* PSO dan ACO<sub>R</sub> (PSOACO<sub>R</sub>) secara sekuensial untuk memprediksi konsumsi energi primer Indonesia. Faktor-faktor yang digunakan untuk menentukan nilai konsumsi energi berupa nilai GDP, GNI, populasi, impor, dan ekspor.

## 3. DASAR TEORI

### 3.1. Regresi Linear Berganda

Pemodelan regresi banyak dipakai untuk memprediksi konsumsi energi primer karena tergolong sederhana dan mudah, beberapa diantaranya, regresi linear (Deka, et al., 2016), regresi linear dan kuadratik (Kiran, et al., 2012), serta regresi linear, eksponensial, dan kuadratik (Yu, et al., 2012). Regresi linear berganda digunakan untuk mengukur pengaruh variabel bebas ( $X_i$ ) lebih dari satu terhadap variabel terikat ( $Y$ ) (Pascual, et al., 2016). Pemodelan regresi linear berganda ditunjukkan dalam Persamaan 1.

$$Y = b_0 + \sum_{i=1}^k b_i X_i \pm \epsilon \quad (1)$$

dimana  $b_0$  adalah intersep. Intersep adalah rata-rata nilai  $Y$  saat  $X_i$  bernilai 0.  $b_i$  merupakan koefisien kemiringan regresi dari variabel bebas  $X_i$ . Untuk mencari nilai  $\epsilon$  (*random error*) didapat dari  $\epsilon_i = Y_i - \hat{Y}_i$ , dimana  $Y_i$  adalah nilai aktual

ke- $i$ , dan  $\hat{Y}_i$  adalah nilai prediksi ke- $i$ .

### 3.2. Particle Swarm Optimization

*Particle swarm optimization* (PSO) adalah salah teknik metaheuristik *stochastic* yang diperkenalkan oleh Kennedy dan Eberhart pada tahun 1995 untuk menyelesaikan permasalahan kontinyu (Bonyadi, et al., 2014). Dalam PSO, solusi potensial disebut partikel, bergerak dalam ruang pencarian mengikuti partikel optimum sebelumnya dengan meng-*update* posisi partikel setiap iterasinya.

Tahap inialisasi pada PSO berupa inialisasi kecepatan partikel, inialisasi partikel secara *uniformly distributed*, dan inialisasi Pbest dan Gbest. Pada tahap iterasi, kecepatan partikel di-*update* menggunakan Persamaan 2.

$$v_i^d(t+1) = w \cdot v_i^d(t) + c_1 \cdot r_1 \cdot (pbest_i^d(t) - x_i^d(t)) + c_2 \cdot r_2 \cdot (gbest_i^d(t) - x_i^d(t)) \quad (2)$$

dimana  $c_1$  dan  $c_2$  bernilai konstan untuk setiap iterasi. Nilai kedua koefisien ini yang sering digunakan adalah 2 atau 2.05 atau 1.496 (Bonyadi, et al., 2014).  $r_1$  dan  $r_2$  merupakan bilangan random *uniformly distributed* yang terletak antara (0,1).

*Update* kecepatan yang dihasilkan harus melalui proses *velocity clamping* untuk mencegah terjadinya *velocity explosion*. Jika nilai  $v_i^d(t+1)$  lebih besar dari batas atas  $v_{max}^d$  maka nilainya akan diganti oleh  $v_{max}^d$ , begitupun sebaliknya jika lebih kecil dari batas bawah  $-v_{max}^d$  maka nilainya akan diganti oleh  $v_{max}^d$ .

Untuk menentukan  $v_{max}$  dan  $-v_{max}$  Marini & Walczak (2015) menggunakan Persamaan 3 dimana  $k$  adalah nilai konstanta dengan nilai antara 0-1,  $x_{max}^d$  adalah batas atas ruang pencarian dimensi ke- $d$ , dan  $x_{min}^d$  adalah batas terbawahnya.

$$v_{max}^d = k \frac{(x_{max}^d - x_{min}^d)}{2} \quad (3)$$

Untuk meng-*update* posisi partikel maka nilai setiap dimensi ke- $d$  dari partikel baru ke- $i$  dihitung menggunakan Persamaan 4, dimana  $x_i^d(t)$  adalah nilai partikel iterasi sebelumnya dan  $v_i^d(t+1)$  adalah kecepatan partikel yang saat ini.

$$x_i^d(t+1) = x_i^d(t) + v_i^d(t+1) \quad (4)$$

Terakhir *update* Pbest dan Gbest. Setiap partikel menyimpan posisi terbaik yang pernah dicapai sebelumnya dalam Pbest yang

ditentukan dari baik tidaknya nilai *fitness*, dan nilai terbaik dari keseluruhan Pbest disimpan dalam Gbest.

### 3.3. Ant Colony Optimization for Continuous Domain

Pada ACO<sub>R</sub> kumpulan solusi disimpan dalam sebuah *solution archive*  $T$ . Pada metode hybrid pada penelitian ini tabel solusi disebut tabel partikel, namun tetap mengacu pada *solution archive*  $T$  yang sama pada ACO<sub>R</sub>. Struktur solusi *archive* ditunjukkan pada Gambar 2.

$s_1$	$s_1^1$	$s_1^2$	. .	$s_1^d$	. .	$s_1^D$	$f(s_1)$	$\omega_1$
$s_2$	$s_2^1$	$s_2^2$	. .	$s_2^d$	. .	$s_2^D$	$f(s_2)$	$\omega_2$
	.	.		.		.	.	.
	.	.		.		.	.	.
	.	.		.		.	.	.
$s_i$	$s_i^1$	$s_i^2$	. .	$s_i^d$	. .	$s_i^D$	$f(s_i)$	$\omega_i$
	.	.		.		.	.	.
	.	.		.		.	.	.
	.	.		.		.	.	.
$s_g$	$s_g^1$	$s_g^2$	. .	$s_g^d$	. .	$s_g^D$	$f(s_g)$	$\omega_g$
	.	.		.		.	.	.
	.	.		.		.	.	.
	.	.		.		.	.	.
$s_k$	$s_k^1$	$s_k^2$	. .	$s_k^d$	. .	$s_k^D$	$f(s_k)$	$\omega_k$

Gambar 2. *Archive* solusi pada ACO<sub>R</sub>

solusi diurutkan berdasarkan nilai *fitness*-nya, dimulai dari yang terbaik contoh untuk permasalahan *global minimum* maka solusi dengan *fitness* terkecil akan berada paling atas, sehingga nilai  $f(s_1) \leq f(s_2) \leq \dots \leq f(s_i) \leq \dots \leq f(s_k)$ . Setiap solusi diasosiasikan dengan  $\omega$  dengan besar nilai  $\omega_1 \geq \omega_2 \geq \dots \geq \omega_l \geq \dots \geq \omega_k$ . Langkah-langkah ACO<sub>R</sub> secara sederhana berupa beberapa tahap inialisasi yakni inialisasi solusi secara *random* dengan *uniformly distributed*, urutkan solusi mulai dari solusi dengan *fitness* terbaik, inialisasi sbest, hitung  $\omega$  dengan menggunakan Persamaan 5.

$$\omega_i = \frac{1}{qk\sqrt{2\pi}} e^{-(i-1)^2/2q^2k^2} \quad (5)$$

hitung peluang  $p_i$  (Persamaan 6) berdasarkan nilai  $\omega_i$  yang akan digunakan untuk proses pemilihan semut menggunakan *roulette wheel* (Huang & Huang, 2013).

$$p_i = \frac{\omega_i}{\sum_{i=1}^k \omega_i} \quad (6)$$

Lakukan perulangan sebanyak  $m$  kali untuk membuat semut baru yang berjumlah  $m \leq k$



dengan memilih salah satu solusi  $s_i$  dengan roulette wheel. Setelah solusi  $s_g$  terpilih kemudian hitung nilai sigma perdimensi solusi terpilih menggunakan Persamaan 7.

$$\sigma_g^d = \xi \sum_{i=1}^k \frac{|s_i^d - s_g^d|}{k-1} \quad (7)$$

dimana  $\xi$  dengan nilai  $\xi > 0$ , mempunyai efek yang sama dengan *evaporation rate* ada ACO. Semakin besar nilai  $\xi$ , maka tingkat konvergensi akan semakin melambat (Socha & Dorigo, 2008).  $s_i^d$  adalah nilai solusi ke- $i$  dimensi ke- $d$ ,  $s_g^d$  adalah solusi terpilih dimensi ke- $d$  dan  $k$  merupakan *archiveSize*.

Untuk setiap dimensi ke- $d$  semut baru, *generate* random  $z$  yang terdistribusi secara normal (*normally distributed*) untuk digunakan pada Persamaan 8.

$$s_m^d = s_g^d + z \cdot \sigma_g^d \quad (8)$$

dimana  $s_m^d$  adalah nilai solusi dimensi ke- $d$  semut baru ke- $m$ ,  $\sigma_g^d$  merupakan nilai standar deviasi atau sigma dimensi ke- $d$ , dan  $s_g^d$  adalah nilai solusi dimensi ke- $d$  yang terpilih menggunakan *roulette wheel*.

Setelah semut baru di-*generate*, gabungkan dan urutkan solusi semut baru dengan solusi sebelumnya. Hapus solusi terburuk agar sesuai ukuran *archiveSize* dan *update* sbest.

### 3.4. Perhitungan Tingkat Kesalahan

Untuk mengetahui seberapa besar tingkat kesalahan pemodelan regresi linear prediksi konsumsi energi primer yang dihasilkan, diperlukan metode untuk menghitung tingkat kesalahan prediksi. Dalam penelitian ini digunakan metode *Mean Absolute Percentage Error* (MAPE), metode ini paling tepat digunakan karena tingkat kesalahan dinyatakan dalam skala yang berbeda (Azadeh, et al., 2013). Menurut Tsai, et al. (2016) nilai akurasi dikategorikan sangat baik jika MAPE yang dihasilkan kurang dari 10%, dan dikategorikan baik jika MAPE antara 10-20%. Rumus MAPE ditunjukkan pada Persamaan 9.

$$MAPE = \frac{\sum_{i=1}^n |Y_i - \hat{Y}_i| / Y_i}{n} \times 100\% \quad (9)$$

dimana  $Y_i$  adalah nilai aktual,  $\hat{Y}_i$  nilai hasil prediksi, dan  $n$  adalah jumlah data.

## 4. PREDIKSI KONSUMSI ENERGI PRIMER MENGGUNAKAN REGRESI LINEAR – HYBRID PSO DAN ACO<sub>R</sub>

### 4.1. Data Penelitian

Data diperoleh dari dua situs internet resmi yakni World Bank berupa variabel GNI, GDP, populasi, impor, dan ekspor Indonesia dengan nilai kurs jual 1 US\$ = 13612 IDR, serta data konsumsi energi primer Indonesia yang diperoleh dari British Petroleum. Data-data tersebut dimulai dari tahun 1960-2016, karena terdapat data yang tidak ada maka data yang dipakai hanya dari tahun 1967-2016 saja.

### 4.2. Pemodelan Regresi Linear - PSOACO<sub>R</sub>

Prediksi energi dikembangkan dari pemodelan regresi linear-PSOACO<sub>R</sub> untuk menemukan *global minimum*. Lima indikator ekonomi yakni GNI, GDP, populasi, impor, dan ekspor Indonesia digunakan untuk memprediksi konsumsi energi primer Indonesia. Pada penelitian ini prediksi konsumsi energi primer dimodelkan dalam bentuk pemodelan regresi linear berganda seperti pada Persamaan 10 berikut:

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + b_3X_3 + b_4X_4 + b_5X_5 \quad (10)$$

dimana  $b_0$  adalah intersep regresi,  $b_1, b_2, b_3, b_4, b_5$  merupakan bobot kemiringan koefisien regresi, dan  $X_i$  adalah variabel bebas (GNI, GDP, populasi, impor, dan ekspor).

Tujuan utama pencarian intersep dan koefisien kemiringan regresi yakni mencari *fittest model* persamaan regresi dari data latih. Fungsi *fitness* dari model tersebut yakni pada Persamaan 11.

$$fitness = \sum_{r=1}^R (Y_r - \hat{Y}_r)^2 \quad (11)$$

dimana  $Y_r$  adalah nilai aktual konsumsi energi primer pada tahun ke- $r$ .  $\hat{Y}_r$  adalah nilai prediksi konsumsi energi primer pada tahun ke- $r$ .

Tahap-tahap prediksi konsumsi energi primer menggunakan *hybrid* PSO dan ACO<sub>R</sub> seperti yang ditunjukkan pada Gambar 3.

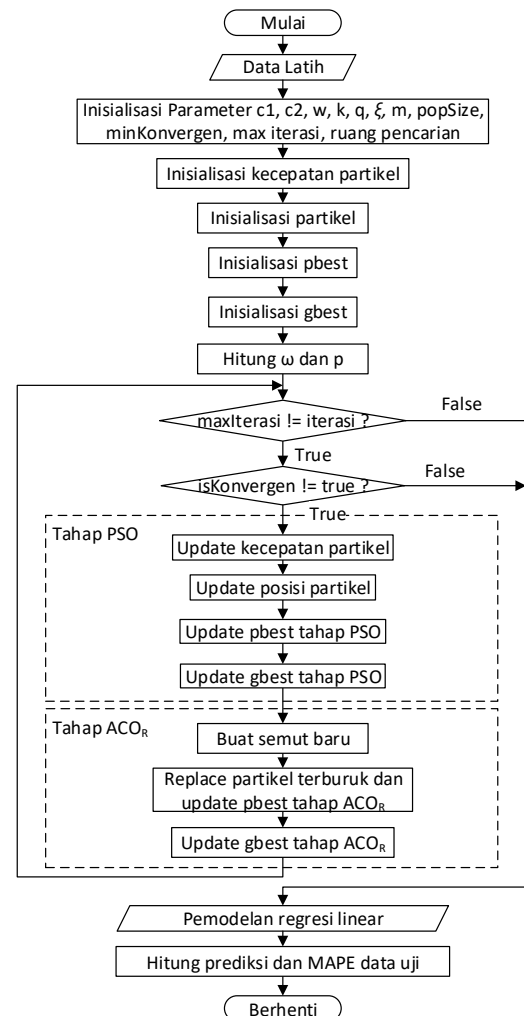
1. Mengambil data latih dari tahun 1967 sampai 2006 sekaligus data uji mulai tahun 2007 sampai 2016 yang disimpan dalam database SQLite berupa data konsumsi energi primer, GNI, GDP, populasi, impor, dan ekspor Indonesia.
2. Menentukan parameter PSOACO<sub>R</sub> berupa nilai  $c1, c2, w, k$  *velocity clamping*,  $q, \xi, m, popSize$ , min konvergen, dan max iterasi.
3. Inisialisasi tabel partikel secara *uniformly distributed*.
4. Inisialisasi kecepatan awal partikel dengan

- nilai sebesar 0 untuk semua partikel
5. Inisialisasi Pbest dengan menyalin semua nilai partikel awal beserta *fitness*-nya pada tabel partikel
6. Inisialisasi Gbest yakni Pbest dengan *fitness* terkecil
7. Hitung nilai  $\omega$  dengan Persamaan 5 dan peluang  $p$  dengan Persamaan 6
8. *Update* kecepatan partikel dengan Persamaan 2
9. *Update* posisi partikel dengan Persamaan 4
10. *Update* Pbest tahap PSO dengan membandingkan Pbest iterasi sebelumnya dengan partikel baru. Jika *fitness* partikel baru lebih baik dari Pbest iterasi sebelumnya maka ganti Pbest dengan set solusi partikel baru tersebut.
11. *Update* Gbest tahap PSO dengan mengganti Gbest iterasi sebelumnya dengan Pbest terbaik iterasi saat ini. Jika Pbest terbaik memiliki *fitness* lebih baik daripada *fitness* Gbest iterasi sebelumnya, maka ganti Gbest dengan Pbest terbaik.
12. Buat semut baru menggunakan Persamaan 7 dan 8.
13. *Replace* partikel terburuk dan *update* Pbest tahap ACO<sub>R</sub>. *Replace* partikel terburuk berupa penggantian partikel terburuk dengan set solusi semut baru yakni jika *fitness* semut baru lebih baik daripada *fitness* partikel terburuk. Jika kondisi tersebut terpenuhi, maka lakukan juga *update* Pbest tahap ACO<sub>R</sub> hanya pada Pbest ke- $i$  yang sejajar dengan partikel terburuk yang telah diganti. Saat *fitness* semut baru tidak lebih baik daripada *fitness* partikel terburuk maka lompat proses ini.
14. *Update* Gbest tahap ACO<sub>R</sub> yakni jika *fitness* semut baru lebih baik daripada Gbest tahap PSO maka ganti Gbest dengan set solusi semut baru.
15. Menghitung prediksi konsumsi energi primer menggunakan Persamaan 10 dan hitung MAPE data uji dengan Persamaan 9.

## 5. PENGUJIAN DAN ANALISIS

Pengujian dilakukan untuk mengetahui pengaruh beberapa parameter yang diuji terhadap nilai *fitness* data latih yang dihasilkan. Untuk nilai parameter tetap awal yakni nilai  $w$ ,  $k$ ,  $q$ , dan  $\xi$  masing-masing 0.7, 0.5, 0.005, dan 0.7. Nilai parameter min konvergen, max iterasi, *popSize*, dan  $m$  masing-masing 50, 1000, 100, dan 2, sedangkan ruang pencarian intersep


regresi sebesar [100, 100] dan koefisien kemiringan regresi sebesar [-10, 10]. Data latih yang dipakai mulai dari tahun 1967 sampai tahun 2006. Jika parameter sudah diuji dan memperoleh nilai parameter terbaik maka lakukan penggantian parameter tersebut untuk digunakan pengujian selanjutnya.



Gambar 3. Flowchart pemodelan regresi-PSOACO<sub>R</sub>


### 5.1. Pengujian Nilai $c1$ $c2$ Terhadap Nilai *Fitness*

Berdasarkan Gambar 4 nilai rata-rata *fitness*  $c1$  dan  $c2$  sebesar 1.496 merupakan nilai terbaik dengan *fitness* 1086.4 sebelum naik lagi saat pengujian dengan nilai  $c1$  dan  $c2$  sebesar 1.5. Jika nilai  $c1$  dan  $c2$  diperbesar lagi dari 1.492 maka rata-rata *fitness* yang diperoleh cenderung lebih buruk, hal ini terjadi karena menurut Bonyadi, et al. (2014) nilai  $c1$  dan  $c2$  yang paling banyak dipakai salah satunya yakni 1.496.


Gambar 4. Rata-rata *fitness* nilai *c1* dan *c2*

### 5.2. Pengujian Nilai *w* Terhadap Nilai *Fitness*

Berdasarkan Gambar 5 nilai rata-rata *fitness* dengan nilai *w* sebesar 0.7298 merupakan nilai *w* terbaik. Nilai *w* yang semakin mendekati 1 maka akan terjadi perlambatan tingkat konvergensi sehingga banyak partikel baru memiliki posisi yang berdekatan dengan partikel sebelumnya dan memerlukan iterasi lebih banyak untuk mencapai nilai yang mendekati *global minimum*.

Gambar 5. Rata-rata *fitness* nilai *w*

### 5.3. Pengujian Nilai *k* Velocity Clamping Terhadap Nilai *Fitness*


Gambar 6. Rata-rata *fitness* nilai *k*

Berdasarkan Gambar 6 nilai *k* terburuk yakni 0.8 dengan nilai *fitness* 1132.7. Nilai rata-rata *fitness* terbaik diperoleh dengan nilai *k* sebesar 0.6 dengan nilai *fitness* terendah 1090. Alasan nilai *k* dari 0.7 sampai dengan 1 memperoleh nilai rata-rata *fitness* cenderung memburuk salah satu yakni banyak partikel yang


keluar dari ruang pencarian yang disebabkan oleh perubahan kecepatan yang terlalu drastis, sehingga hasil *fitness* jauh dari yang diharapkan (*velocity explosion*).

### 5.4. Pengujian Nilai *q* Terhadap Nilai *Fitness*

Berdasarkan Gambar 7 nilai *q* sebesar 0.002 menghasilkan nilai *fitness* hanya 1156.0 dan merupakan yang terburuk diantara percobaan dengan nilai yang lain. Nilai rata-rata *fitness* terbaik diperoleh dengan nilai *q* sebesar 0.007 dengan nilai rata-rata *fitness* 1086.7. Hal ini terjadi karena partikel yang dipilih untuk *generate* semut baru cenderung lebih memilih partikel dengan *fitness* bukan yang terbaik dan sulit mencapai *global minimum*.

Gambar 7. Rata-rata *fitness* nilai *q*

### 5.5. Pengujian Nilai $\xi$ Terhadap Nilai *Fitness*


Gambar 8. Rata-rata *fitness* nilai  $\xi$ 

Berdasarkan Gambar 8 nilai rata-rata *fitness* dengan nilai  $\xi$  bersifat fluktuatif sebesar 0.6 merupakan yang terburuk. Nilai rata-rata *fitness* terbaik diperoleh dengan nilai  $\xi$  sebesar 1 dengan nilai *fitness* terkecil diantara percobaan lainnya yakni 1085 karena jika nilai  $\xi > 0$ , maka tingkat konvergensi cenderung semakin melambat (Socha & Dorigo, 2008).

### 5.6. Pengujian Jumlah Semut Baru Terhadap Nilai *Fitness*


Pada Gambar 9 jumlah semut baru paling baik dicapai dengan jumlah semut sebanyak 10

dengan rata-rata *fitness* paling kecil yakni sebesar 1053.8 Jumlah yang direkomendasikan oleh Socha & Dorigo (2008) yakni  $\geq 2$  untuk beragam besar *popSize*.



Gambar 9. Rata-rata *fitness* jumlah semut baru


### 5.7. Pengujian Jumlah *PopSize* Terhadap Nilai *Fitness*



Gambar 10. Rata-rata *fitness* jumlah *popSize*

Berdasarkan Gambar 10 nilai *fitness* terburuk dihasilkan saat jumlah *popSize* sebanyak 20 dan terus mengalami perbaikan nilai *fitness* sampai *popSize* berjumlah 120.

### 5.8. Pengujian Kriteria Berhenti Terhadap Nilai *Fitness*



Gambar 11. Rata-rata *fitness* kriteria berhenti

Berdasarkan Gambar 11 nilai rata-rata *fitness* terbaik diperoleh dengan nilai max iterasi dan min konvergen sebesar 2000 dan 100 dengan nilai *fitness* 1082.4. Jika jumlah iterasi ditingkatkan lagi menjadi 2500 iterasi maka rata-

rata *fitness* yang diperoleh tidak lebih baik dengan nilai *fitness* dengan nilai max iterasi dan min konvergen sebesar 2000 dan 100, penyebabnya solusi sudah mencapai konvergen sebelum mencapai jumlah iterasi yang diinginkan disamping efek buruk lainnya berupa waktu komputasi yang lebih lama.

### 5.9. Pengujian Pemodelan Regresi Linear terhadap MAPE pada Data Uji

Pemodelan regresi linear diperoleh dari pembentukan bobot intersep dan kemiringan koefisien regresi ( $b_0, b_1, b_2, b_3, b_4, b_5$ ). Bobot-bobot ini dioptimasi menggunakan PSOACO<sub>R</sub>, nilainya diambil dari Gbest iterasi terakhir PSOACO<sub>R</sub>. Pemodelan-pemodelan regresi linear yang terbentuk dibandingkan MAPE-nya dan dipilih yang terbaik.

Dari Tabel 4 dapat diketahui rata-rata MAPE yang diperoleh dengan menggunakan PSOACO<sub>R</sub> pada data uji mulai dari tahun 2007 sampai 2016 sebesar 10.1%. Pemodelan regresi linear terbaik yang terbentuk dengan MAPE 10.03% yakni:

$$Y = -60.632 + 1.764X_1 - 1.826X_2 + 0.559X_3 - 0.737X_4 + 1.670X_5 \quad (12)$$

Berdasarkan bobot pemodelan regresi pada Persamaan 12 maka dapat dilakukan prediksi konsumsi energi Indonesia dari tahun 2007 sampai 2016 (data uji). Untuk melihat lebih jelas nilai hasil prediksi beserta nilai aktualnya dapat melihat Tabel 1.

Tabel 1. Perbandingan nilai aktual dan prediksi

Tahun	Nilai Aktual	Nilai Prediksi	Selisih
2007	132.87	139.47	6.6
2008	131.30	149.4	18.1
2009	136.01	135.52	0.49
2010	149.31	169.3	19.99
2011	162.83	206.85	44.02
2012	170.54	177.57	7.03
2013	174.24	167.89	6.35
2014	162.90	160.01	2.89
2015	164.83	148.05	16.78
2016	175.04	138.17	36.87
MAPE			10.03

Berdasarkan Tabel 4, hasil pengujian sebanyak 10 kali menghasilkan nilai MAPE tidak fluktuatif maka metode tersebut dianggap valid. Nilai MAPE terbesar yang dihasilkan sebesar 10.26% dan MAPE terkecil sebesar



10.03% dengan rata-rata MAPE 10.1% menunjukkan selisih MAPE terbesar dari rata-ratanya hanya 0.16%.

#### 5.10. Perbandingan antara regresi-PSOACO<sub>R</sub> dengan regresi-PSO dan regresi-ACO<sub>R</sub>

Berdasarkan pengujian yang telah dilakukan pada skenario pengujian untuk mengetahui hasil MAPE data uji pada pemodelan regresi yang terbentuk maka selanjutnya dilakukan perbandingan prediksi menggunakan regresi-PSO dan regresi-ACO<sub>R</sub> secara terpisah.

Menurut Huang & Huang, (2013) untuk membandingkan antara PSOACO<sub>R</sub>, PSO, dan ACO<sub>R</sub> diperlukan penyetaraan perhitungan evaluasi. Sebuah evaluasi diartikan jumlah perhitungan nilai *fitness* pada suatu metode dikali jumlah max iterasi. Jumlah tersebut harus dicapai oleh PSO dan ACO<sub>R</sub> agar dinilai adil dalam melakukan perbandingan. Untuk lebih jelasnya, perhitungan jumlah evaluasi ditunjukkan pada Tabel 2, sedangkan parameter-parameter hasil perhitungan evaluasi dapat dilihat pada Tabel 3.

Tabel 2. Perhitungan evaluasi

Metode	Perhitungan jumlah evaluasi
PSO	Jumlah partikel × max iterasi
ACO <sub>R</sub>	Jumlah semut baru × max iterasi
PSOACO <sub>R</sub>	(Jumlah partikel + Jumlah semut baru) × max iterasi

Tabel 3. Parameter PSOACO<sub>R</sub>, PSO, dan ACO<sub>R</sub>

Parameter	PSOACO <sub>R</sub>	PSO	ACO <sub>R</sub>
<i>c1</i>	1.496	1.496	
<i>c2</i>	1.496	1.496	
<i>w</i>	0.7298	0.7298	
<i>k velocity clamping</i>	0.6	0.6	
<i>q</i>	0.007		0.001
<i>ξ</i>	1		1
max iterasi	2000	2000	2000
min konvergen	100	100	500
<i>popSize</i>	120	130	
<i>archiveSize</i>			300
<i>m semut baru</i>	10		130
total evaluasi	260000	260000	260000

Hasil rata-rata MAPE pada Tabel 4 menunjukkan PSOACO<sub>R</sub> tidak lebih baik daripada PSO sendiri. Dari hasil 10 kali percobaan pemodelan regresi-PSO memiliki performa terbaik dengan nilai rata-rata MAPE 10.09% selisih tipis dibanding regresi-PSOACO<sub>R</sub> yang hanya 10.10%, dan regresi-

ACO<sub>R</sub> pada posisi terburuk dengan nilai rata-rata MAPE sebesar 11.62%.

Tabel 4. Hasil perbandingan MAPE

Percobaan ke-	Regresi-PSOACO <sub>R</sub>	Regresi-PSO	Regresi-ACO <sub>R</sub>
1	10.09	10.00	11.19
2	10.06	10.14	11.27
3	10.12	10.15	8.38
4	10.1	10.12	13.02
5	10.04	9.95	13.33
6	10.03	10.15	9.39
7	10.26	10.19	12.23
8	10.11	9.95	14.12
9	10.09	10.25	12.35
10	10.09	9.99	10.95
Avg.MAPE	10.10	10.09	11.62

Dari Tabel 4 dapat disimpulkan bahwa PSOACO<sub>R</sub> memiliki rata-rata MAPE tidak lebih baik jika dibandingkan dengan pemodelan regresi linear-PSO biasa meski hanya memiliki selisih rata-rata *fitness* sebesar 0.01%, hal ini disebabkan karena metode PSO sudah tergolong sangat baik untuk menyelesaikan permasalahan kontinyu pada penelitian ini dan hibridasi antara dua metode optimasi dimana PSO memiliki hasil terbaik dan ACO<sub>R</sub> memiliki hasil terburuk menghasilkan perpaduan dengan nilai MAPE diantara keduanya. PSO sendiri memang dirancang untuk menyelesaikan kasus optimasi kontinyu.

Tabel 5. Hasil perbandingan waktu komputasi

Percobaan ke-	Regresi-PSOACO <sub>R</sub>	Regresi-PSO	Regresi-ACO <sub>R</sub>
1	79437	59078	164821
2	81901	62309	166671
3	77672	62900	168273
4	79540	58721	168211
5	80334	60552	165968
6	78109	61295	163290
7	79911	59302	167956
8	81452	61486	164730
9	80754	57347	166558
10	79883	60283	167869
Avg. (ms)	79899	60327	166435

Dari segi waktu komputasi seperti yang ditunjukkan pada Tabel 5 terlihat pemodelan regresi-PSO lebih superior dibandingkan regresi-PSOACO<sub>R</sub> maupun regresi-ACO<sub>R</sub>. Salah satu penyebabnya karena demi menyetarakan

jumlah evaluasi maka ukuran *archiveSize* ACO<sub>R</sub> membengkak menjadi 300 yang otomatis membuat waktu komputasi menjadi lebih lama. Sedangkan pemodelan regresi-PSOACO<sub>R</sub> memiliki waktu komputasi lebih lama dari PSO penyebabnya karena pemodelan ini bersifat *hybrid* sehingga memerlukan kode program lebih banyak meskipun dari sisi *popSize* lebih sedikit daripada regresi linear-PSO.

Jika diteliti lagi dari bagian yang dioptimasi dari PSO oleh ACO<sub>R</sub> yakni bagian tabel partikel, pbest, dan gbest letak atau posisi yang di-*replace* menjadi jauh dari posisi sebelumnya meski dari sisi *fitness* lebih baik. Jika tahap iterasi kembali lagi ke tahap PSO maka partikel, pbest, gbest yang di-*replace* oleh ACO<sub>R</sub> akan diperbaiki lagi sehingga lebih mempersulit PSOACOR untuk mencapai *global minimum*.

## 6. KESIMPULAN

Berdasarkan hasil penelitian pemodelan regresi pada prediksi konsumsi energi primer Indonesia menggunakan PSOACO<sub>R</sub>, maka dapat diambil kesimpulan:

Nilai *c1*, *c2*, *w*, *k*, *q*, dan  $\xi$  terbaik masing-masing 1.496, 1.496, 0.7298, 0.6, 0.007, dan 1. Besar *popSize* sebanyak 120 dan 10 semut baru merupakan jumlah terbaik. Kriteria berhenti terbaik yakni max iterasi sebesar 2000 dan min konvergen sebanyak 100.

Tingkat akurasi pemodelan regresi linear menggunakan PSOACO<sub>R</sub> mendapat rata-rata MAPE sebesar 10.1% yang masuk dalam kategori baik. MAPE terbaik diperoleh sebesar 10.03%.

Dari hasil perbandingan antara regresi linear-PSOACO<sub>R</sub> dengan regresi linear-PSO dan regresi linear-ACO<sub>R</sub> mendapati bahwa regresi linear-PSOACO<sub>R</sub> tidak lebih baik daripada regresi linear-PSO biasa dari sisi hasil MAPE pada data uji maupun dari waktu komputasi.

## 7. DAFTAR PUSTAKA

- Azadeh, A., R., B. & Asadzadeh, S. M., 2013. *Optimum estimation and forecasting of renewable energy consumption by artificial neural networks*. Renewable and Sustainable Energy Reviews, Issue 27, pp. 605-612.
- Barak, S. & Sadegh, S. S., 2016. *Forecasting energy consumption using ensemble ARIMA-ANFIS hybrid algorithm*. Electrical Power and Energy Systems, Issue 82, pp. 92-104.
- Bonyadi, M. R., Michalewicz, Z. & Li, X., 2014. *An analysis of the velocity updating rule of the particle swarm optimization algorithm*. Heuristics.
- Deka, A., Hamta, N., Behzad, E. & Behdad, S., 2016. *Predictive Modeling Techniques to Forecast Energy Demand in the United States: A Focus on Economic and Demographic Factors*. Journal of Energy Resources Technology, Issue 138, pp. 1-9.
- Huang, C.-L. & Huang, W.-C., 2013. *Hybridization strategies for continuous ant colony optimization and particle swarm optimization applied to data clustering*. Applied Soft Computing, Issue 13, pp. 3864-3872.
- Kiran, M. S., Özceylan, E., Gündüz, M. & Paksoy, T., 2012. *A novel hybrid approach based on Particle Swarm Optimization and Ant Colony Algorithm to forecast energy demand of Turkey*. Energy Conversion and Management, Issue 53, pp. 75-83.
- Marini, F. & Walczak, B., 2015. *Particle swarm optimization (PSO). A tutorial*. Chemometrics and Intelligent Laboratory Systems, Issue 149, pp. 153-165.
- Pascual, C. V., Hurtado, A. S., Martinez, E. M. & Gaspar, J. M. P., 2016. *Client threshold prediction in biometric signature recognition by means of Multiple Linear Regression and its use for score normalization*. Pattern Recognition, Issue 55, pp. 1-13.
- Socha, K. & Dorigo, M., 2008. *Ant Colony Optimization for Continuous Domains*. European Journal of Operational Research, Issue 185, p. 1155-1173.
- Suganthi, L. & Samuel, A. A., 2012. *Energy models for demand forecasting-A review*. Renewable and Sustainable Energy Reviews, Issue 16, pp. 1223-1240.
- Tsai, S.-B. et al., 2016. *Models for forecasting growth trends in renewable energy*. Renewable and Sustainable Energy Reviews, Issue 2016, pp. 1-10.